本文档为技术演示用的虚构示例（星澜科技为虚构企业），与任何真实企业无关，仅用于 Agent 项目知识库演示。

星澜科技 开放平台 API 限流与配额说明

第 1 章 概述

1.1 接口形态

开放平台对外提供 REST 接口，统一使用 HTTPS 与 JSON 报文。所有请求须携带 AK/SK 签名（HMAC-SHA256）与请求时间戳，时间戳与服务端偏差超过 5 分钟将被拒绝。

1.2 鉴权方式

服务端返回的访问令牌（JWT）有效期 2 小时，过期需使用刷新令牌换取。刷新令牌有效期 30 天，同一账号最多同时存在 3 个有效刷新令牌。

第 2 章 限流档位

2.1 各档位限额

套餐档位	每秒请求数 QPS	每日调用量	单次批量上限
免费版	10	5 万次	100 条
标准版	100	500 万次	500 条
企业版	1000	5 亿次	2000 条
尊享版	按合同约定	按合同约定	按合同约定

2.2 计数口径

限流按账号维度统计，同一账号下的多个应用共享额度；每日调用量以北京时间零点为重置点。失败请求（4xx 中的参数错误、鉴权失败）计入调用量，服务端 5xx 不计入。

第 3 章 超限处理

3.1 返回约定

超限时返回 HTTP 429，响应头包含 Retry-After（秒）与当前套餐额度信息，响应体中的错误码为 RateLimitExceeded。

3.2 退避建议

客户端应实现指数退避重试，建议间隔 1 秒、2 秒、4 秒，最多重试 3 次；禁止无间隔重试，短时间内大量重试将被判定为异常流量。

3.3 持续超限降级

连续 10 分钟超限的账号将被降级至当前额度的 50%，持续 30 分钟后解除；同一账号每月触发 3 次以上的，需要重新评估套餐。

第 4 章 配额调整

4.1 提额申请

客户可通过工单申请临时提额，注明业务场景、期望额度与持续时间。标准版以上客户可在 3 个工作日内完成审批，临时额度最长 7 天。

4.2 长期扩容

长期超出套餐额度的，建议升级套餐或购买专属集群；专属集群支持独立限流策略与独立监控指标。

第 5 章 错误码

HTTP 状态码	错误码	含义与处理建议
401	Unauthorized	签名错误或令牌过期，重新获取令牌
403	Forbidden	无接口权限，申请权限或检查套餐
429	RateLimitExceeded	触发限流，按 Retry-After 退避
500	InternalError	服务端异常，携带 requestId 提交工单

第 6 章 变更与通知

6.1 版本与变更

接口变更遵循向后兼容原则；涉及不兼容调整的，提前 30 天在开放平台公告并邮件通知已订阅的客户。

6.2 停服与维护

计划内维护提前 3 个工作日通知，单次维护不超过 4 小时；紧急安全维护不受此限，但须在恢复后 24 小时内出具说明。